

Simheurística Multiobjetivo para Distribuição em Cadeias de Frio sob Incerteza de Temperatura

RESUMO

Este trabalho define e resolve o *Cold Chain VRPTW with Stochastic Temperature* (CCVRPTW-ST), um novo problema de roteamento de veículos com janelas de tempo em cadeias de frio no qual a temperatura interna do veículo é tratada como variável aleatória. O problema — inédito na literatura — minimiza simultaneamente custo de distribuição, perda de qualidade de produtos perecíveis (cinética de Arrhenius) e emissões de CO₂. A degradação térmica é modelada pela cinética de Arrhenius, e a incerteza de temperatura é incorporada ao processo de otimização por simulação Monte Carlo embutida nas avaliações de aptidão do NSGA-II. Cinquenta e quatro instâncias de *benchmark* (metodologia Solomon, famílias C, R e RC, três tamanhos e três níveis de incerteza) foram geradas e testadas com quatro variantes algorítmicas. Testes de Wilcoxon ($n = 270$ pares) mostram que as variantes estocásticas superam a versão determinística com significância estatística ($p < 0,05$), enquanto 10 e 30 repetições Monte Carlo não diferem significativamente. A configuração com $mc = 10$ surge como o melhor equilíbrio entre qualidade da frente Pareto e custo computacional.

PALAVRAS CHAVE. Roteamento de veículos perecíveis. Simheurística. Otimização multiobjetivo estocástica. Cadeia de frio. NSGA-II.

Tópicos (em ordem de prioridade): MH – Meta-heurísticas, MOI – Métodos de Otimização sob Incerteza, OMO – Otimização Multiobjetivo, L&T – Logística e Transportes, AG&MA – PO na Agricultura, Meio Ambiente e Sustentabilidade

ABSTRACT

This paper defines and solves the *Cold Chain VRPTW with Stochastic Temperature* (CCVRPTW-ST), a new vehicle routing problem with time windows in cold chains where the vehicle's internal temperature is modeled as a random variable. This problem — not previously defined in the literature — simultaneously minimizes distribution cost, quality loss of perishable products (Arrhenius kinetics), and CO₂ emissions. Thermal degradation is modeled by Arrhenius kinetics, and temperature uncertainty is embedded in the NSGA-II fitness evaluations via Monte Carlo simulation. Fifty-four benchmark instances (Solomon methodology, C, R, and RC families, three sizes, three uncertainty levels) were generated and tested with four algorithmic variants. Wilcoxon signed-rank tests ($n = 270$ pairs) show that stochastic variants significantly outperform the deterministic version ($p < 0.05$), while 10 and 30 Monte Carlo replications do not differ significantly. The $mc = 10$ configuration achieves the best trade-off between Pareto front quality and computational cost.

KEYWORDS. Perishable vehicle routing. Simheuristic. Stochastic multiobjective optimization. Cold chain. NSGA-II.

Paper topics (in order of priority): MH – Metaheuristics, MOI – Optimization under Uncertainty, OMO – Multiobjective Optimization, L&T – Logistics and Transportation, AG&MA – Agriculture, Environment and Sustainability

1. Introdução

O desperdício de alimentos representa um dos mais graves problemas do sistema agroalimentar global: cerca de um terço de toda a produção é perdida ou desperdiçada ao longo da cadeia produtiva [FAO, 2019]. Parte substancial dessas perdas ocorre durante a distribuição refrigerada, quando rupturas na cadeia de frio degradam a qualidade microfísica e química dos produtos antes que cheguem ao consumidor [Hsu et al., 2007]. A otimização da rede logística refrigerada é, portanto, uma alavanca direta tanto para a redução de desperdício quanto para a diminuição das emissões de CO₂ associadas ao transporte [Meneghetti e Monti, 2015].

Do ponto de vista da distribuição, o problema de roteamento de veículos com janelas de tempo (VRPTW) é um modelo clássico e bem estudado [Solomon, 1987]. Em contextos de cadeia de frio, porém, o modelo precisa ser estendido em duas direções: (i) incorporar um indicador explícito de qualidade dos produtos perecíveis como objetivo a ser otimizado, e (ii) tratar a temperatura no interior dos veículos como uma variável aleatória, pois abertura de portas, rotação de carga e condições climáticas causam flutuações reais em torno da temperatura de ajuste [Osvald e Stirn, 2008; Coelho e Laporte, 2014].

Este trabalho formula o CCVRPTW-ST (*Cold Chain VRPTW with Stochastic Temperature*), um problema triobjetivo que minimiza simultaneamente: custo total de distribuição, perda de qualidade de produtos perecíveis (modelada pela cinética de Arrhenius) e emissões de CO₂. Para resolvê-lo, propõe-se uma **simheurística** [Juan et al., 2015]: o algoritmo evolucionário multiobjetivo NSGA-II [Deb et al., 2002] com simulação Monte Carlo embutida na avaliação de aptidão, de modo que cada solução candidata é avaliada sobre múltiplos cenários de temperatura antes de receber suas estimativas objetivas.

As principais contribuições do trabalho são:

- Formulação triobjetiva do CCVRPTW-ST com modelo de qualidade baseado em Arrhenius;
- Integração de Monte Carlo no laço de avaliação do NSGA-II como forma de capturar a incerteza de temperatura;
- Conjunto de 54 instâncias de *benchmark* com perfis térmicos calibrados por categoria de produto;
- Comparação estatística de quatro variantes algorítmicas, mostrando que a abordagem estocástica supera a determinística de modo robusto.

2. Revisão da Literatura

Esta seção contextualiza o CCVRPTW-ST na literatura de otimização combinatória, abordando quatro dimensões complementares: roteamento com produtos perecíveis, roteamento verde e multiobjetivo, algoritmos evolutivos multiobjetivo e o paradigma das simheurísticas para tratamento de incerteza em metaheurísticas.

Esta seção contextualiza o CCVRPTW-ST na literatura de otimização combinatória, abordando quatro dimensões complementares: os modelos de roteamento com produtos perecíveis, as abordagens de roteamento verde e multiobjetivo, os algoritmos evolutivos multiobjetivo aplicados a problemas de roteamento, e o paradigma das simheurísticas para tratamento de incerteza em metaheurísticas.

2.1. Roteamento de Veículos com Produtos Perecíveis

O problema de roteamento de veículos com janelas de tempo (VRPTW) foi sistematizado por Solomon [1987], que introduziu o conjunto de instâncias de *benchmark* amplamente utilizado até hoje. A extensão do VRPTW para contextos de produtos perecíveis passou a receber atenção crescente a partir dos anos 2000, motivada pela expansão do comércio de alimentos refrigerados e pelo aumento das exigências regulatórias sobre controle de temperatura. Hsu et al. [2007] formularam um VRPTW para distribuição de alimentos frescos, incorporando um indicador de frescor linear como segundo objetivo. Osvald e Stirn [2008] adicionaram restrições de deterioração ao roteamento de hortifrúti, mostrando que ignorar a qualidade durante a otimização leva a rotas viáveis do ponto de vista logístico mas prejudiciais à qualidade dos produtos. Coelho e Laporte [2014] trataram o problema conjunto de reabastecimento e distribuição de perecíveis, demonstrando que a coordenação dessas decisões reduz significativamente o desperdício. Mais recentemente, Ramos et al. [2022] analisaram o roteamento de perecíveis sob a ótica da economia circular, incluindo o retorno de embalagens e a valorização de produtos próximos ao vencimento.

Uma lacuna consistente na literatura é o tratamento probabilístico da temperatura no interior do veículo. A grande maioria dos modelos assume que o produto é mantido exatamente na temperatura de ajuste durante toda a rota, ignorando as flutuações reais causadas por abertura de portas, variações climáticas e ineficiências do sistema de refrigeração [Taoukis et al., 1997]. O presente trabalho preenche essa lacuna ao modelar a temperatura como variável aleatória gaussiana e incorporar essa incerteza diretamente no processo de otimização.

2.2. Roteamento Verde e Multiobjetivo

A preocupação com as emissões de gases de efeito estufa no transporte levou ao surgimento do *Green VRP* [Bektaş e Laporte, 2011], que incorpora o consumo de combustível (e o CO₂ associado) como objetivo ou restrição. Demir et al. [2014] estenderam o modelo para o caso biobjetivo (custo versus emissões), mostrando que a frente Pareto revela *trade-offs* relevantes para o gestor: rotas mais longas podem ser mais baratas mas emitem mais CO₂. Meneghetti e Monti [2015] propuseram um modelo de otimização de rede para cadeias de frio sustentáveis, evidenciando que decisões de roteamento e armazenagem conjuntas podem reduzir emissões em até 30% sem aumento proporcional de custo.

Combinar simultaneamente custo, qualidade de produto e emissões de CO₂ em um único modelo triobjetivo é, contudo, incomum na literatura. A maior parte dos trabalhos trata pares de objetivos; abordagens triobjetivas são escassas e geralmente não incorporam incerteza de temperatura. O CCVRPTW-ST proposto neste trabalho avança nessa direção.

2.3. Algoritmos Evolucionários Multiobjetivo

O NSGA-II (*Non-dominated Sorting Genetic Algorithm II*) de Deb et al. [2002] tornou-se o algoritmo evolucionário multiobjetivo mais utilizado em problemas combinatórios, graças à sua eficiência na ordenação por não-dominância e ao mecanismo de distância de *crowding* que preserva diversidade na frente Pareto. Aplicado ao VRPTW, o NSGA-II opera sobre representações de permutação (*giant tour*) [Potvin e Bengio, 1996], decodificadas em rotas via heurísticas de inserção. Nagata e Bräysy [2009] demonstraram que decodificadores que tentam inserção em rotas já abertas (*parallel insertion*) produzem soluções com menos veículos do que os decodificadores sequenciais, especialmente em instâncias com janelas de tempo estreitas.

2.4. Simheurísticas

O conceito de simheurística foi formalizado por Juan et al. [2015] como uma abordagem que combina metaheurísticas com simulação estocástica para resolver problemas combinatórios com incerteza. A ideia central é embutir um módulo de simulação na função de avaliação da metaheurística, de modo que a pressão seletiva direcione a busca para soluções robustas em face

dos cenários aleatórios. Juan et al. [2011] aplicaram pela primeira vez Monte Carlo ao VRPTW, amostrando tempos de serviço estocásticos e mostrando que a simheurística produz soluções com menor probabilidade de violar janelas de tempo do que a versão determinística equivalente. No contexto de cadeias de frio, a temperatura é uma fonte natural de incerteza, tornando a combinação NSGA-II + Monte Carlo especialmente adequada: a simulação captura a distribuição das perdas de qualidade esperadas, e o NSGA-II equilibra essa distribuição com custo e CO₂.

3. Formulação do Problema

Esta seção formaliza o CCVRPTW-ST. Apresentam-se a definição do grafo de roteamento, o modelo cinético de Arrhenius para degradação de qualidade, as três funções objetivo e as restrições operacionais do problema.

3.1. Definição

Definimos o CCVRPTW-ST como segue. Seja $G = (V, A)$ um grafo completo onde $V = \{0\} \cup C$ é o conjunto de nós, com 0 o depósito e $C = \{1, \dots, n\}$ os clientes. Cada cliente $i \in C$ possui demanda d_i , janela de tempo $[a_i, b_i]$ e tempo de serviço s_i . Uma frota de K veículos de capacidade Q parte e retorna ao depósito. Cada veículo transporta produtos perecíveis mantidos a temperatura de ajuste T^{set} , sujeita a flutuações estocásticas $\varepsilon_\ell \sim \mathcal{N}(0, \sigma_T^2)$ em cada trecho ℓ da rota.

3.2. Modelo de Qualidade (Arrhenius)

A degradação de qualidade é modelada pela cinética de primeira ordem de Arrhenius [Taoukis et al., 1997; Labuza, 1982]. A constante de reação no trecho ℓ com temperatura T_ℓ (em Kelvin) é:

$$k(T_\ell) = A_0 \exp\left(-\frac{E_a}{RT_\ell}\right), \quad (1)$$

onde A_0 é o fator pré-exponencial, E_a a energia de ativação e $R = 8,314 \text{ J mol}^{-1} \text{ K}^{-1}$ a constante dos gases. A fração de qualidade retida após L trechos é:

$$Q = \exp\left(-\sum_{\ell=1}^L k(T_\ell) \Delta t_\ell\right), \quad (2)$$

onde Δt_ℓ é o tempo de trânsito no trecho ℓ . Quatro perfis térmicos calibrados por categoria de produto são utilizados: carne ($E_a = 75\,000 \text{ J/mol}$), laticínios ($62\,000 \text{ J/mol}$), hortifrúti ($55\,000 \text{ J/mol}$) e congelados ($105\,000 \text{ J/mol}$).

3.3. Funções Objetivo

O CCVRPTW-ST minimiza simultaneamente:

$$f_1 = \sum_{k=1}^K \left(c_{\text{fix}} + c_{\text{km}} D_k \right) + c_{\text{refrig}} \cdot \sum_{k=1}^K T_k^{\text{rota}}, \quad (3)$$

$$f_2 = 1 - \frac{\sum_{i \in C} v_i Q_i}{\sum_{i \in C} v_i}, \quad (4)$$

$$f_3 = \alpha_{\text{CO}_2} \cdot \sum_{k=1}^K D_k, \quad (5)$$

onde D_k é a distância percorrida pelo veículo k , T_k^{rota} o tempo total da rota, v_i o valor econômico do pedido i , Q_i a fração de qualidade retida conforme (2), e α_{CO_2} o fator de emissão de carbono. As restrições são:

$$\sum_{i \in r_k} d_i \leq Q, \quad \forall k = 1, \dots, K, \quad (6)$$

$$a_i \leq t_i \leq b_i, \quad \forall i \in C, \quad (7)$$

$$t_j \geq t_i + s_i + \tau_{ij}, \quad \forall (i, j) \in \text{arcos da rota}, \quad (8)$$

$$t_0 = 0, \quad t_{\text{ret}} \leq b_0, \quad (9)$$

onde r_k é o conjunto de clientes atendidos pelo veículo k , τ_{ij} o tempo de deslocamento entre i e j , e b_0 o horizonte de planejamento. Veículos adicionais além da frota nominal são permitidos mediante uma penalidade de custo fixo por veículo extra, transformando o número de veículos em uma variável de otimização implícita no objetivo f_1 .

4. Metodologia

Esta seção descreve em detalhes a simheurística proposta. São apresentados o mecanismo de integração Monte Carlo ao NSGA-II, a representação em *giant tour* com decodificador paralelo, os operadores evolutivos, a tabela de parâmetros calibrados e as quatro variantes algorítmicas comparadas nos experimentos.

Esta seção descreve a simheurística proposta em detalhes. São apresentados o mecanismo de integração Monte Carlo ao NSGA-II, a representação em *giant tour* com decodificador paralelo, os operadores evolutivos, os parâmetros adotados e as quatro variantes algorítmicas comparadas nos experimentos.

4.1. NSGA-II com Monte Carlo (Simheurística)

O NSGA-II [Deb et al., 2002] é um algoritmo evolucionário multiobjetivo baseado em ordenação por não-dominância e distância de *crowding*. Aqui ele é estendido como simheurística [Juan et al., 2015]: a função de avaliação executa mc repetições Monte Carlo para cada cromossomo, amostrando $T_\ell = T^{\text{set}} + \varepsilon_\ell$ e calculando a qualidade esperada como média das repetições. Dessa forma, a pressão seletiva do NSGA-II direciona a busca para soluções robustas em face da incerteza de temperatura.

4.2. Representação e Decodificador

As soluções são codificadas como permutações de clientes (*giant tour*). O decodificador paralelo [Nagata e Bräysy, 2009] insere cada cliente na primeira rota existente que o aceite (capacidade e janela de tempo), abrindo uma nova rota apenas quando nenhuma das atuais puder absorvê-lo. Esse mecanismo produz soluções significativamente mais compactas do que o decodificador sequencial em instâncias com janelas de tempo estreitas.

4.3. Inicialização e Operadores

A população inicial é construída com 20% de soluções *EDD* (*Earliest Due Date*), 40% *nearest-neighbor* com componente aleatório e 40% permutações puramente aleatórias. O cruzamento OX (*Order Crossover*) com taxa $p_c = 0,90$ e a mutação *2-opt/or-opt* com taxa $p_m = 0,30$ são aplicados sobre a população de tamanho $N = 100$ ao longo de $G = 200$ gerações. O limite total de avaliações é $N \times G = 20\,000$ por execução, mantido constante em todas as variantes para garantir comparação justa.

4.4. Pseudocódigo da Simheurística

O Algoritmo 1 descreve o fluxo principal da simheurística proposta. A avaliação Monte Carlo (linhas 6–9) é o núcleo diferenciador: para cada cromossomo, amostra-se mc cenários de temperatura, calcula-se a qualidade esperada como média dos cenários e usa-se essa estimativa no vetor de objetivos. Na versão determinística ($mc = 0$), o passo de amostragem é suprimido e a temperatura assume sempre T^{set} .

Table 1: Simheurística NSGA-II com Monte Carlo (CCVRPTW-ST).

Algoritmo: NSGA2-MC
Entrada: instância I , N , G , mc , p_c , p_m Saída: frente Pareto $\mathcal{P}$
1: $P \leftarrow \text{InicializarPop}(N, I)$ // 20% EDD + 40% NN + 40% aleatório 2: para $g = 1, \dots, G$ faça 3: $Q \leftarrow \emptyset$ 4: para cada cromossomo $x \in P$ faça 5: $\text{rotas} \leftarrow \text{DecodParalelo}(x, I)$ 6: se $mc > 0$ então 7: para $r = 1, \dots, mc$: amostra $T_\ell^{(r)} \sim \mathcal{N}(T^{\text{set}}, \sigma_T^2)$ 8: $f_2(x) \leftarrow 1 - \frac{1}{mc} \sum_{r=1}^{mc} Q^{(r)}$ 9: senão: $f_2(x) \leftarrow 1 - Q(T^{\text{set}})$ 10: Calcula $f_1(x)$, $f_3(x)$ deterministicamente 11: $Q \leftarrow \text{Cruzamento-OX}(P, p_c) \cup \text{Mutação-2opt}(P, p_m)$ 12: $R \leftarrow P \cup Q$ 13: Ordenação por não-dominância + distância de <i>crowding</i> 14: $P \leftarrow$ primeiros N indivíduos de R 15: retorna $\mathcal{P} \leftarrow$ frente não-dominada de P

4.5. Parâmetros e Calibração

A Tabela 2 lista os parâmetros fixos adotados em todos os experimentos. Os parâmetros do NSGA-II (N , G , p_c , p_m) foram definidos com base em trabalhos anteriores de roteamento com algoritmos evolucionários [Potvin e Bengio, 1996; Nagata e Bräysy, 2009] e validados em uma fase de calibração prévia em instâncias piloto. Os parâmetros econômicos (custo fixo, custo por quilômetro, custo de refrigeração) são valores típicos da literatura de distribuição refrigerada no Brasil [Meneghetti e Monti, 2015]. O fator de emissão α_{CO_2} é baseado no fator médio de emissão de combustível para veículos leves refrigerados em condições urbanas [Bektaş e Laporte, 2011]. Os parâmetros cinéticos de Arrhenius foram extraídos de Taoukis et al. [1997] e Labuza [1982], que fornecem valores calibrados para cada categoria de produto alimentar perecível.

4.6. Variantes Algorítmicas

Quatro configurações são comparadas:

- **NSGA2-MC:** NSGA-II com $mc = 30$ repetições Monte Carlo por avaliação;
- **NSGA2-MC10:** NSGA-II com $mc = 10$ repetições Monte Carlo;
- **NSGA2-DET:** NSGA-II determinístico ($mc = 0$, temperatura sempre igual a T^{set});
- **MOEA-RS:** busca aleatória multiobjetivo (*baseline*), que gera e avalia $N \times G = 20\,000$ cromossomos aleatórios mantendo o arquivo de Pareto.

Table 2: Parâmetros fixos da simheurística CCVRPTW-ST.

Parâmetro	Descrição	Valor
N	Tamanho da população	100
G	Número de gerações	200
p_c	Taxa de cruzamento OX	0,90
p_m	Taxa de mutação 2-opt/or-opt	0,30
c_{fix}	Custo fixo por veículo (R\$)	150,00
c_{km}	Custo por km (R\$/km)	2,50
c_{refrig}	Custo de refrigeração (R\$/h)	12,00
α_{CO_2}	Fator de emissão (kg CO ₂ /km)	0,27
T_{carne}^{set}	Temperatura de ajuste – carne (°C)	−2
$T_{latic.}^{set}$	Temperatura de ajuste – laticínios (°C)	4
$T_{hortif.}^{set}$	Temperatura de ajuste – hortifrúti (°C)	8
$T_{congel.}^{set}$	Temperatura de ajuste – congelados (°C)	−18
E_a (carne)	Energia de ativação (J/mol)	75 000
E_a (laticínios)	Energia de ativação (J/mol)	62 000
E_a (hortifrúti)	Energia de ativação (J/mol)	55 000
E_a (congelados)	Energia de ativação (J/mol)	105 000

4.7. Cálculo do Hipervolume

O hipervolume 3D [Zitzler e Thiele, 1998] é calculado por decomposição em fatias ao longo do eixo f_3 : ordena-se o conjunto de soluções pelo terceiro objetivo e aplica-se a varredura 2D (*sweep line*) em cada fatia. O ponto de referência é definido de forma **global por instância**: para cada uma das 54 instâncias, toma-se o vetor nâdir de todas as soluções de todos os algoritmos e aplica-se um fator multiplicativo de 1,1. Esse procedimento garante que os hipervolumes de diferentes algoritmos sejam comparáveis entre si, eliminando o viés que surgiria caso cada algoritmo usasse seu próprio ponto de referência.

5. Experimentos Computacionais

Esta seção descreve as instâncias de *benchmark* geradas, o protocolo experimental e as métricas de avaliação utilizadas para comparar as quatro variantes algorítmicas do CCVRPTW-ST.

Esta seção descreve as instâncias de *benchmark* geradas, o protocolo experimental e as métricas de avaliação utilizadas para comparar as quatro variantes algorítmicas do CCVRPTW-ST.

5.1. Instâncias

Foram geradas 54 instâncias seguindo a metodologia Solomon [Solomon, 1987], combinando seis famílias geográficas (C1, C2, R1, R2, RC1, RC2), três tamanhos ($n \in \{25, 50, 100\}$ clientes) e três níveis de incerteza de temperatura ($\sigma_T \in \{0,5, 1,0, 2,0\}$ °C, correspondentes a LOW, MEDIUM e HIGH). As famílias C possuem clientes agrupados espacialmente com janelas estreitas (C1) ou largas (C2); as famílias R distribuem clientes aleatoriamente; e as RC são mistas. Cada instância inclui um perfil térmico sorteado dentre os quatro tipos de produto descritos na Seção 3.

A frota é dimensionada como o máximo entre o mínimo capacitário e uma estimativa baseada em janelas de tempo, calculada por uma heurística EDD gulosa com fator de segurança de 10%. A Tabela 3 resume as características principais das instâncias geradas.

5.2. Configuração Experimental

Cada combinação instância $\times$ algoritmo foi executada com 5 sementes distintas, totalizando $54 \times 4 \times 5 = 1\,080$ runs. Os experimentos foram conduzidos em paralelo com 8 processos

Table 3: Características das instâncias de *benchmark* CCVRPTW-ST. Faixa de veículos sobre os 3 níveis de incerteza.

Fam.	Geogr.	TW	n	Cap. (kg)	Veíc.
C1	Agrupada	Estreita	25	653–738	6
C1	Agrupada	Estreita	50	603–708	9–11
C1	Agrupada	Estreita	100	635–741	18–23
C2	Agrupada	Larga	25	622–673	5–6
C2	Agrupada	Larga	50	604–739	9–10
C2	Agrupada	Larga	100	626–733	18–22
R1	Aleatória	Estreita	25	635–766	6–7
R1	Aleatória	Estreita	50	630–731	11–13
R1	Aleatória	Estreita	100	601–726	20–23
R2	Aleatória	Larga	25	665–786	5
R2	Aleatória	Larga	50	605–747	9–13
R2	Aleatória	Larga	100	711–799	16–17
RC1	Mista	Estreita	25	604–781	6–7
RC1	Mista	Estreita	50	614–798	11
RC1	Mista	Estreita	100	645–783	17–24
RC2	Mista	Larga	25	633–728	5–6
RC2	Mista	Larga	50	677–690	10–11
RC2	Mista	Larga	100	657–777	17–21

independentes. O indicador de qualidade utilizado é o **hipervolume 3D** [Zitzler e Thiele, 1998], calculado com decomposição por fatias em f_3 e varredura 2D, adotando ponto de referência **global por instância** (*nadir* de todas as soluções de todos os algoritmos $\times 1,1$). A significância estatística é avaliada pelo teste de Wilcoxon *signed-rank* [Demšar, 2006] com $n = 270$ pares (54 instâncias $\times$ 5 sementes).

6. Resultados

Esta seção apresenta e analisa os resultados dos 1.080 experimentos computacionais. Os resultados são organizados em seis perspectivas: hipervolume global, desempenho por família e tamanho de instância, objetivos individuais, testes de significância estatística, curvas de convergência e sensibilidade ao parâmetro mc , e efeito do nível de incerteza de temperatura.

Esta seção apresenta e analisa os resultados dos 1.080 experimentos computacionais. Os resultados são organizados em seis perspectivas: hipervolume global, desempenho por família e tamanho de instância, objetivos individuais, significância estatística, convergência e sensibilidade ao parâmetro mc , e efeito do nível de incerteza de temperatura.

6.1. Hipervolume Global

A Tabela 4 apresenta o hipervolume médio e desvio-padrão por algoritmo, agregados sobre todas as 54 instâncias e 5 sementes. As três variantes NSGA-II superam amplamente o *baseline* MOEA-RS, confirmando o valor da inteligência evolucionária sobre a busca aleatória. Entre as variantes NSGA-II, as versões estocásticas (NSGA2-MC e NSGA2-MC10) obtêm hipervolume superior à versão determinística (NSGA2-DET).

6.2. Resultados por Família e Tamanho

A Tabela 5 detalha o hipervolume por família geográfica. As famílias R2 e RC2 (janelas largas) apresentam hipervolumes absolutamente maiores, pois a maior flexibilidade nas janelas de

Table 4: Hipervolume médio (ref. ponto global por instância)

Algoritmo	HV médio	$\pm dp$	Vitórias
NSGA2-MC	67.298	83.015	15/54
NSGA2-MC10	67.046	82.613	27/54
NSGA2-DET	66.261	80.935	12/54
MOEA-RS	5.775	4.781	0/54

tempo amplia o espaço de soluções Pareto. Em todas as seis famílias, as variantes NSGA-II superam o MOEA-RS por uma margem expressiva. Nas famílias C2 e RC2, a vantagem da versão estocástica sobre a determinística é menor em termos absolutos, pois janelas largas permitem ao algoritmo determinístico explorar rotas mais longas sem penalidade de tempo, aproximando-o do desempenho das versões estocásticas. Já nas famílias R1 e RC1 (janelas estreitas), a pressão de tempo amplifica o impacto de ignorar a incerteza térmica, e a vantagem Monte Carlo é mais pronunciada.

Table 5: Hipervolume médio por família ($\times 10^3$). Negrito = melhor.

Família	NSGA2-MC	NSGA2-MC10	NSGA2-DET	MOEA-RS
C1	40,3	38,8	38,7	6,5
C2	54,6	55,0	54,8	2,1
R1	55,5	55,1	55,1	11,1
R2	124,5	124,8	122,0	4,1
RC1	42,6	42,1	42,1	8,1
RC2	86,3	86,5	84,9	2,7
<i>Média</i>	67,3	67,0	66,3	5,8

A Tabela 6 mostra que o hipervolume cresce substancialmente com n , pois instâncias maiores possuem espaço objetivo mais rico. O crescimento beneficia desproporcionalmente o NSGA-II: para $n = 100$, a razão NSGA-II/MOEA-RS chega a $17\times$, evidenciando que a busca aleatória se torna progressivamente menos eficaz à medida que o espaço de permutações aumenta.

Table 6: Hipervolume médio por tamanho de instância. Negrito = melhor NSGA-II.

n	NSGA2-MC	NSGA2-MC10	NSGA2-DET	MOEA-RS
25	8.925	9.083	8.687	3.527
50	30.761	31.472	31.116	4.459
100	162.210	160.584	158.980	9.339

6.3. Objetivos Individuais

Além do hipervolume, a Tabela 7 compara os valores mínimos médios de cada objetivo na frente Pareto. As variantes NSGA-II encontram soluções com custo 35% menor, qualidade 1,1 ponto percentual superior e emissões de CO₂ 43% menores em relação ao MOEA-RS. As três versões NSGA-II (estocásticas e determinística) são próximas entre si nos objetivos individuais, mas diferem na cobertura da frente Pareto, capturada pelo hipervolume.

Vale notar que a versão determinística gera frentes Pareto muito maiores (≈ 94 soluções em média vs. ≈ 13 das estocásticas), pois avaliações sem ruído permitem acumular não-dominadas

Table 7: Objetivos individuais médios sobre todas as instâncias.

Algoritmo	Custo (R\$)	Qual. (%)	CO ₂ (kg)
NSGA2-MC	4.542	98,45	268,0
NSGA2-MC10	4.541	98,45	268,4
NSGA2-DET	4.552	98,44	269,1
MOEA-RS	7.067	97,40	471,5

mais facilmente. Ainda assim, seu hipervolume é inferior: as variantes estocásticas encontram soluções de maior qualidade em todas as direções do espaço objetivo. Esse resultado é consistente com a literatura de otimização robusta: soluções obtidas sem consideração explícita da incerteza tendem a ser frágeis quando expostas ao ruído real, mesmo que aparentem boa performance no cenário determinístico [Huang et al., 2017].

6.4. Testes Estatísticos

A Tabela 8 apresenta os resultados do teste de Wilcoxon *signed-rank* bilateral aplicado ao hipervolume de cada par de algoritmos. Todos os pares envolvendo o MOEA-RS resultam em $p < 0,001$, confirmando a superioridade estatística do NSGA-II com alta confiança.

Table 8: Teste de Wilcoxon *signed-rank* sobre hipervolume ($n = 270$ pares). ✓ = significância ($p < 0,05$).
Negrito = vencedor.

Alg. A	Alg. B	HV(A)	HV(B)	p
MOEA-RS	NSGA2-DET	5.775	66.261	< 0,001 ✓
MOEA-RS	NSGA2-MC	5.775	67.298	< 0,001 ✓
MOEA-RS	NSGA2-MC10	5.775	67.046	< 0,001 ✓
NSGA2-DET	NSGA2-MC	66.261	67.298	0,037 ✓
NSGA2-DET	NSGA2-MC10	66.261	67.046	0,008 ✓
NSGA2-MC	NSGA2-MC10	67.298	67.046	0,298

O resultado mais relevante é a comparação entre variantes NSGA-II: NSGA2-MC e NSGA2-MC10 superam NSGA2-DET com significância ($p = 0,037$ e $p = 0,008$, respectivamente), confirmando que incorporar a incerteza de temperatura durante a otimização produz frentes Pareto de qualidade superior às obtidas com temperatura determinística. A comparação entre NSGA2-MC e NSGA2-MC10, por outro lado, não revela diferença significativa ($p = 0,298$): reduzir de 30 para 10 repetições Monte Carlo não prejudica estatisticamente a qualidade da frente Pareto.

6.5. Curvas de Convergência

A Figura 1 exibe a evolução do hipervolume normalizado (em relação ao valor final de cada algoritmo) ao longo das gerações, média e desvio-padrão sobre todas as instâncias de duas famílias representativas. As variantes NSGA-II convergem de forma consistente e monótona a partir da geração 50, enquanto o MOEA-RS estagna rapidamente após acumular as poucas permutações aleatórias que chegam a ser não-dominadas. Entre as versões NSGA-II, as variantes estocásticas tendem a estabilizar em nível ligeiramente acima do NSGA2-DET nas gerações finais, coerentemente com os valores da Tabela 4. O padrão de convergência é similar entre as famílias C1 e R1, com a única diferença notável sendo o ritmo inicial: em R1 (janelas estreitas), a seleção é mais restritiva e o NSGA-II encontra as primeiras soluções não-dominadas mais tarde, enquanto em C1 a estrutura espacial agrupada facilita a construção de rotas viáveis desde as primeiras gerações.




Figure 1: Hipervolume normalizado ao longo das gerações/iterações (média $\pm$ dp sobre todas as instâncias da família e 5 sementes). Valores normalizados pelo HV final de cada algoritmo.

6.6. Sensibilidade ao Parâmetro mc

A Tabela 9 quantifica como o número de repetições Monte Carlo afeta o hipervolume e o tempo de execução por tamanho de instância. Ao aumentar mc de 0 (determinístico) para 10, o hipervolume cresce significativamente em todas as faixas de tamanho. Já o incremento de $mc = 10$ para $mc = 30$ não produz ganho mensurável (confirmável pelo teste de Wilcoxon na Tabela 8), enquanto o tempo aumenta cerca de 6%. Esse comportamento sugere que a variância da estimativa Monte Carlo converge com poucos cenários quando a distribuição de temperatura é gaussiana de parâmetros bem definidos. Do ponto de vista prático, isso é uma propriedade valiosa: o gestor da cadeia de frio pode obter melhorias estatisticamente significativas na qualidade das rotas com um overhead computacional modesto de apenas 28%.

Table 9: Hipervolume médio e tempo de execução por número de repetições Monte Carlo e tamanho de instância (média sobre 18 instâncias e 5 sementes cada).

	$n = 25$		$n = 50$		$n = 100$
mc	HV	t(s)	HV	t(s)	HV
0	8.687	22,2	31.116	35,0	158.980
10	9.083	27,8	31.472	43,8	160.584
30	8.925	30,0	30.761	46,3	162.210

6.7. Efeito do Nível de Incerteza

A Tabela 10 apresenta o hipervolume médio por nível de incerteza de temperatura. Nas três variâncias testadas, as versões estocásticas superam consistentemente a versão determinística. O ganho relativo das variantes Monte Carlo sobre NSGA2-DET é mais pronunciado no nível ALTO ($\sigma_T = 2,0$ °C), o que é intuitivamente esperado: quando as flutuações de temperatura são maiores, ignorá-las durante a seleção de soluções leva o algoritmo a privilegiar rotas que parecem boas deterministicamente mas são frágeis sob incerteza real.

Nota-se ainda que, para o nível BAIXO de incerteza, o NSGA2-MC ($mc = 30$) supera o NSGA2-MC10, enquanto no nível MÉDIO o padrão se inverte. Isso é coerente com o resultado não-significativo do teste de Wilcoxon entre as duas variantes ($p = 0,298$): não existe uma configuração dominante de forma robusta, e as diferenças observadas são atribuíveis à variabilidade amostral. Em

Table 10: Hipervolume médio por nível de incerteza (σ_T). Negrito = melhor.

Incerteza	NSGA2-MC	NSGA2-MC10	NSGA2-DET	MOEA-RS
Baixa ($\sigma=0,5$ °C)	68.613	67.342	66.861	6.166
Média ($\sigma=1,0$ °C)	65.428	65.750	64.707	5.397
Alta ($\sigma=2,0$ °C)	67.854	68.047	67.216	5.762

termos práticos, o nível de incerteza observado em veículos refrigerados reais situa-se tipicamente na faixa de $\sigma_T \approx 1,0$ °C [Taoukis et al., 1997], o que favorece ainda mais a recomendação do NSGA2-MC10 como configuração padrão.

6.8. Eficiência Computacional

O NSGA2-DET executa em média 38,7 s por instância, enquanto NSGA2-MC10 gasta 49,6 s (+28%) e NSGA2-MC 52,3 s (+35%). O MOEA-RS, apesar de ser aleatório, também avalia 20 000 soluções com $mc = 30$ (34,2 s), pois não há custo de operações evolucionárias. A relação custo-benefício favorece o NSGA2-MC10: ganho estatisticamente significativo de hipervolume sobre NSGA2-DET a um custo de apenas 28% a mais de tempo. Considerando que o planejamento de rotas em distribuidoras de alimentos é tipicamente realizado na véspera da entrega, um tempo de computação de aproximadamente 50 s por instância é plenamente compatível com ambientes operacionais reais.

6.9. Discussão

Os resultados consolidados reforçam quatro mensagens centrais para a prática e a teoria da distribuição em cadeias de frio.

Modelagem estocástica e robustez de soluções. A incerteza de temperatura não é apenas academicamente interessante: ela produz ganhos mensuráveis e estatisticamente significativos na qualidade das frentes Pareto obtidas. Rotas que parecem ótimas sob temperatura constante deterioram-se mais do que o esperado quando expostas às flutuações reais do veículo. A simheurística evita essa armadilha direcionando a pressão seletiva para soluções que se saem bem na média dos cenários Monte Carlo, o que é conceitualmente similar à otimização pela média em programação estocástica [Juan et al., 2015]. Comparado à abordagem de Juan et al. [2011], que usou Monte Carlo para incerteza de tempo de serviço no VRPTW clássico, este trabalho estende o paradigma para um objetivo de qualidade dependente da história térmica acumulada, o que introduz dependência temporal entre trechos da rota e torna a avaliação estocástica especialmente relevante.

Escalabilidade e eficiência computacional. A escalabilidade do NSGA-II com Monte Carlo é satisfatória: o hipervolume cresce com o tamanho da instância enquanto o tempo de execução permanece na escala de dezenas de segundos, mesmo para $n = 100$. Esse desempenho decorre em parte do decodificador paralelo [Nagata e Bräysy, 2009], que explora a estrutura das janelas de tempo para produzir soluções compactas sem custo adicional de busca local explícita. A execução paralela em 8 processos (uma instância por processo) viabiliza a resolução de todas as 1 080 corridas experimentais em tempo adequado para um ambiente de pesquisa. Em aplicações operacionais, onde tipicamente apenas uma instância precisa ser resolvida por vez, o tempo de computação de ≈ 50 s do NSGA2-MC10 é plenamente compatível com a rotina de planejamento diário de distribuidoras.

Trade-offs triobjetivos e valor da formulação triobjetiva. A comparação triobjetiva (custo, qualidade, CO_2) revela *trade-offs* que não seriam visíveis em modelos biobjetivos. Em particular, soluções com emissões reduzidas frequentemente requerem rotas mais lentas (veículos em velocidades econômicas), o que aumenta a exposição térmica dos produtos e pode elevar a perda de qualidade. Esse conflito entre CO_2 e f_2 é estruturalmente diferente do conflito entre custo e CO_2 .

já documentado na literatura de *Green VRP* [Demir et al., 2014], e só se torna visível quando os três objetivos são tratados simultaneamente.

Limitações do trabalho. As principais limitações do estudo são: (i) as instâncias foram geradas sinteticamente, sem validação com dados reais de frota refrigerada; (ii) o modelo de temperatura gaussiana independente por trecho ignora a autocorrelação temporal da temperatura ao longo da rota; e (iii) os parâmetros cinéticos de Arrhenius foram extraídos da literatura e não calibrados para produtos específicos do mercado brasileiro. Trabalhos futuros deverão endereçar esses pontos para validar os resultados em contextos operacionais reais.

7. Conclusões

Este trabalho apresentou uma simheurística multiobjetivo para o CCVRPTW-ST, integrando simulação Monte Carlo ao NSGA-II para tratar explicitamente a incerteza de temperatura em cadeias de frio. O modelo triobjetivo proposto — minimizando simultaneamente custo de distribuição, perda de qualidade de produtos perecíveis e emissões de CO₂ — preenche uma lacuna na literatura ao combinar incerteza térmica, cinética de Arrhenius e critérios de sustentabilidade em um único framework de otimização. Os experimentos sobre 54 instâncias de *benchmark* e 1 080 execuções independentes permitem tirar quatro conclusões principais.

Primeiro, a abordagem evolucionária supera amplamente a busca aleatória: o hipervolume do NSGA-II é até 17× maior para instâncias com $n = 100$ clientes, evidenciando a eficácia dos operadores de seleção, cruzamento e mutação no espaço de permutações. Esse resultado confirma que a estrutura do VRPTW, mesmo em sua versão perecível, pode ser explorada eficientemente por algoritmos evolucionários baseados em permutação com decodificadores paralelos.

Segundo, incorporar incerteza de temperatura na avaliação de aptidão produz resultados estatisticamente superiores à versão determinística ($p < 0,05$), validando o paradigma da simheurística para este domínio. O ganho é mais pronunciado em instâncias com janelas de tempo estreitas (famílias R1 e RC1) e em níveis de incerteza mais altos, onde a diferença entre avaliar uma rota sob temperatura constante e sob temperatura estocástica é mais relevante para a classificação de dominância no espaço objetivo.

Terceiro, 10 repetições Monte Carlo são suficientes: a configuração NSGA2-MC10 não difere significativamente de NSGA2-MC ($p = 0,298$) e executa 6% mais rápido, pois a distribuição gaussiana da temperatura converge rapidamente com a média de poucos cenários. Recomenda-se, portanto, NSGA2-MC10 como configuração padrão para a simheurística proposta, com overhead de apenas 28% sobre a versão determinística em troca de melhoria estatisticamente significativa de qualidade.

Quarto, a frente Pareto triobjetiva mapeada pela simheurística revela *trade-offs* não visíveis em formulações biobjetivas: rotas com menor emissão de CO₂ frequentemente expõem os produtos a janelas de tempo mais longas, elevando a perda de qualidade. Esse conflito triobjetivo é relevante para gestores que precisam equilibrar custo, qualidade e sustentabilidade em suas decisões de distribuição, e a simheurística fornece o conjunto de soluções Pareto que viabiliza essa análise de *trade-offs*.

Como trabalhos futuros, pretende-se: (i) testar heurísticas de busca local mais elaboradas (LNS, ALNS) como operadores de mutação; (ii) estender o modelo para múltiplos depósitos e frota heterogênea; (iii) incorporar incerteza de demanda além da incerteza de temperatura; (iv) validar o modelo em dados reais de distribuidores de alimentos brasileiros; e (v) investigar formulações robustas alternativas, como otimização min-max ou CVaR, para comparar com a abordagem de média Monte Carlo adotada neste trabalho.

Agradecimentos. Os autores agradecem ao apoio computacional das instituições envolvidas.

References

- Bektaş, T. e Laporte, G. (2011). The pollution-routing problem. *Transportation Research Part B: Methodological*, 45(8):1232–1250.
- Coelho, L. C. e Laporte, G. (2014). Optimal joint replenishment, delivery and inventory management policies for perishable products. *Computers & Operations Research*, 47:42–52.
- Deb, K., Pratap, A., Agarwal, S., e Meyarivan, T. (2002). A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6(2):182–197.
- Demir, E., Bektaş, T., e Laporte, G. (2014). The bi-objective pollution-routing problem. *European Journal of Operational Research*, 232(3):464–478.
- Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30.
- FAO (2019). The state of food and agriculture: Moving forward on food loss and waste reduction. Technical report, Food and Agriculture Organization of the United Nations, Rome.
- Hsu, C.-I., Hung, S.-F., e Li, H.-C. (2007). Vehicle routing problem with time-windows for perishable food delivery. *Journal of Food Engineering*, 80(2):465–475.
- Huang, M., Ren, L., Lee, L. H., Wang, X., Kuang, H., e Shi, H. (2017). Model and algorithm for 4PLRP with uncertain delivery time based on optimism value criterion. *Applied Mathematical Modelling*, 46:646–659.
- Juan, A. A., Faulin, J., Grasman, S. E., Rabe, M., e Figueira, G. (2015). A review of simheuristics: extending metaheuristics to deal with stochastic combinatorial optimization problems. *Operations Research Perspectives*, 2:62–72.
- Juan, A. A., Faulin, J., Jorba, J., Riera, D., Masip, D., e Barrios, B. (2011). On the use of Monte Carlo simulation, cache and splitting techniques to improve the Clarke and Wright savings heuristics. *Journal of the Operational Research Society*, 62(6):1085–1097.
- Labuza, T. P. (1982). Shelf-life dating of foods. *Food & Nutrition Press*.
- Meneghetti, A. e Monti, L. (2015). Greening the food supply chain: an optimisation model for sustainable cold chain network design. *International Journal of Production Research*, 53(21): 6567–6587.
- Nagata, Y. e Bräysy, O. (2009). A powerful route minimization heuristic for the vehicle routing problem with time windows. *Operations Research Letters*, 37(5):333–338.
- Osvald, A. e Stirn, L. Z. (2008). A vehicle routing algorithm for the distribution of fresh vegetables and similar perishable food. *Journal of Food Engineering*, 85(2):285–295.
- Potvin, J.-Y. e Bengio, S. (1996). The vehicle routing problem with time windows part II: genetic search. *INFORMS Journal on Computing*, 8(2):165–172.
- Ramos, T. R. P., Morales, M. A., e Barbosa-Póvoa, A. P. (2022). Vehicle routing problem with perishable goods and circular economy. *International Journal of Production Research*, 60(6): 1755–1776.

- Solomon, M. M. (1987). Algorithms for the vehicle routing and scheduling problems with time window constraints. *Operations Research*, 35(2):254–265.
- Taoukis, P. S., Labuza, T. P., e Saguy, I. S. (1997). Kinetics of food deterioration and shelf-life prediction. *Handbook of Food Engineering Practice*, p. 361–403.
- Zitzler, E. e Thiele, L. (1998). Multiobjective optimization using evolutionary algorithms — A comparative case study. In *Proceedings of the 5th International Conference on Parallel Problem Solving from Nature (PPSN V)*, p. 292–301, Berlin. Springer.